

Reporte técnico de Actividades Práctico-Experimental Nro. 010

1. Datos Generales

Grupo A:	Isaac Vire Carlos Martinez Erick Rogel Mateo Yanangomez Elvis Guayllas
Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	2
Resultado de aprendizaje de la unidad	Evalúa el comportamiento probabilístico de variables aleatorias continuas mediante el ajuste a la distribución Normal y el cálculo de áreas bajo la curva, aplicando estandarización (puntajes Z) para la toma de decisiones basada en datos empíricos.
Práctica Nro.	010
Título de la Práctica	Inferencia Estadística Multigrupo: Análisis de Varianza (ANOVA de 1 factor) y Pruebas Post-Hoc (Tukey)
Nombre del Docente	Cristian Ramiro Narváez Guillén
Fecha	Martes 22 de junio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

2. Objetivo(s) de la Práctica:

- Diferenciar y ejecutar computacionalmente la prueba T de Student para dos muestras independientes y la prueba T para muestras pareadas utilizando scipy.stats.



- Aplicar el diseño de un experimento comparativo (A/B Test) sobre dos segmentos categóricos del conjunto de datos regional del Proyecto Integrador, determinando si existe una diferencia estadísticamente significativa entre ellos (ABP).
- Investigar y validar matemáticamente el supuesto de igualdad de varianzas (homocedasticidad) mediante la ejecución del Test de Levene antes de comparar medias poblacionales (ABI).

3. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.x|

4. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

5. Procedimiento / Metodología

1. Enfoque PID:

- ABP (Aprendizaje Basado en Problemas): El estudiante ya no compara su región contra un "valor ideal" teórico (Semana 10), sino que ahora divide sus datos regionales en dos grupos reales (ej. Zona Norte vs Zona Sur; Proveedor A vs Proveedor B) para descubrir disparidades sistémicas empíricas.
- ABI (Aprendizaje Basado en Investigación): Indagación sobre qué sucede cuando dos poblaciones tienen niveles de dispersión radicalmente distintos. Se investiga por qué la Prueba T de Welch ajusta automáticamente los grados de libertad para salvar la inferencia.
- Duración sugerida: 120 min. (presencial).

- Modalidad: Ejecución técnica individual, con discusión de impactos en los grupos del Proyecto Integrador.

Tarea 1: Prueba de Hipótesis para Dos Muestras Independientes (A/B Testing)

El objetivo es probar si las medias de dos poblaciones distintas son iguales ($H_0 : \mu_1 = \mu_2$, o de forma equivalente $H_0 : \mu_1 - \mu_2 = 0$).

Estadístico T (asumiendo varianzas iguales):

$$T = \frac{\bar{X}_1 - \bar{X}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

1.

Abra un nuevo Jupyter Notebook llamado APE_011_DosMuestras.ipynb.

2. Escenario: Usted es ingeniero de software y desea saber si el "Algoritmo A" consume menos memoria RAM que el "Algoritmo B". Ejecuta ambos en entornos aislados y registra el consumo en MB.

```
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import ttest_ind

# Datos empíricos (Consumo de RAM en MB)
np.random.seed(42)
memoria_algo_A = np.random.normal(loc=120.5, scale=12.0, size=35)
memoria_algo_B = np.random.normal(loc=128.2, scale=15.0, size=40)

alpha = 0.05

# Ejecución de la prueba T para muestras independientes (2 colas)
stat_ind, p_val_ind = ttest_ind(memoria_algo_A, memoria_algo_B,
equal_var=True)

print("--- A/B Testing: Algoritmo A vs Algoritmo B ---")
print(f"Media Algo A: {np.mean(memoria_algo_A):.2f} MB | Media Algo B: {np.mean(memoria_algo_B):.2f} MB")
print(f"Estadístico T: {stat_ind:.4f}")
```



unl

Universidad
Nacional
de Loja

FEIRNNR - Carrera de Computación

```
print(f"Valor-p: {p_val_ind:.4e}")
```

```
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import ttest_ind
```

```
# Datos empíricos (Consumo de RAM en MB)
np.random.seed(42)
memoria_algo_A = np.random.normal(loc=120.5, scale=12.0, size=35)
memoria_algo_B = np.random.normal(loc=128.2, scale=15.0, size=40)
```

```
alpha = 0.05
```

```
# Ejecución de la prueba T para muestras independientes (2 colas)
stat_ind, p_val_ind = ttest_ind(memoria_algo_A, memoria_algo_B,
equal_var=True)
```

```
print("--- A/B Testing: Algoritmo A vs Algoritmo B ---")
print(f"Media Algo A: {np.mean(memoria_algo_A):.2f} MB | Media Algo B:
{np.mean(memoria_algo_B):.2f} MB")
print(f"Estadístico T: {stat_ind:.4f}")
print(f"Valor-p: {p_val_ind:.4e}")
```

Tarea 2: Prueba de Hipótesis para Muestras Pareadas (Dependientes)

Se usa cuando los datos de ambos grupos provienen de las mismas unidades de observación (ej. métricas del sistema "Antes" y "Después" de aplicar un parche de optimización). Aquí se evalúa la media de las diferencias (

$$d_i = X_{2i} - X_{1i}.$$

$$T = \frac{\bar{d} - \mu_d}{S_d / \sqrt{n}}$$

1.

Escenario: Usted mide el tiempo de latencia de 15 servidores específicos antes y después de instalar un nuevo firewall.

2. Implemente y analice el código con `ttest_rel`:

```
from scipy.stats import ttest_rel

# Latencia en ms (las posiciones en los arrays corresponden al mismo
servidor)
latencia_antes = np.array([45, 52, 48, 55, 60, 42, 49, 58, 51, 46, 50, 47, 53, 59, 44])
latencia_despues = np.array([41, 50, 45, 50, 56, 40, 46, 53, 48, 42, 47, 45, 51, 55,
40])

# Prueba pareada (H1: la latencia "después" es menor, por tanto (antes -
despues) > 0)
# Para evaluar si "después" bajó, usamos una prueba de cola superior sobre
las diferencias (antes - despues)
# SciPy modernos permiten alternative='greater' en ttest_rel
stat_rel, p_val_rel = ttest_rel(latencia_antes, latencia_despues,
alternative='greater')

print("\n--- Análisis Pareado: Impacto del Nuevo Firewall ---")
print(f"Media Diferencias (Antes - Después): {np.mean(latencia_antes -
latencia_despues):.2f} ms")
print(f"Estadístico T Pareado: {stat_rel:.4f}")
print(f"Valor-p (1 cola): {p_val_rel:.4e}")

if p_val_rel < 0.05:
    print("Conclusión: Se RECHAZA H0. El firewall redujo significativamente la
latencia.")
else:
    print("Conclusión: NO se rechaza H0. El firewall no mejoró la latencia.")
```

Tarea 3: Hito del Proyecto - Segmentación y Prueba A/B Regional (ABP)

1. Importe su dataset regional mediante pandas.

2. Identifique una variable categórica dicotómica (o filtre dos categorías específicas de una mayor, ej. ['Sector Rural', 'Sector Urbano'] o ['Enero', 'Julio']).
3. Extraiga la variable cuantitativa de interés para esos dos grupos separándolos en dos DataFrames o Arrays (grupo1 y grupo2).
4. Aplique un A/B Test usando ttest_ind.
5. Redacte un dictamen técnico-estadístico basado en el valor- p obtenido, indicando si las políticas públicas o las decisiones de ingeniería en la región deben tratar a ambos grupos por igual o de forma diferenciada.

Tarea 4: ABI - Supuesto de Homocedasticidad y Prueba de Levene

En la Tarea 1 y 3 usamos equal_var=True. Matemáticamente, la T de Student clásica exige que las varianzas poblacionales de ambos grupos sean iguales ($\sigma_1^2 = \sigma_2^2$).

1. Investigue el Test de Levene (scipy.stats.levene). Su Hipótesis Nula es que las varianzas *son* iguales.
2. Extraiga las variables memoria_algo_A y memoria_algo_B de la Tarea 1.
3. Ejecute el Test de Levene sobre ellas. Imprima el valor- p .
4. Toma de decisión automatizada: Escriba un pequeño bloque if/else en Python que verifique el p -valor de Levene: si $p < 0.05$, indique que existe *Heterocedasticidad* y proceda a ejecutar automáticamente la T de Student con el parámetro equal_var=False (Esta versión se conoce como la Prueba T de Welch).

6. Resultados esperados:

Resultados de la Tarea 1:

```
*** --- A/B Testing: Algoritmo A vs Algoritmo B ---
Media Algo A: 118.91 MB | Media Algo B: 126.71 MB
Estadístico T: -2.5362
Valor-p: 1.3347e-02
*** --- A/B Testing: Algoritmo A vs Algoritmo B ---
Media Algo A: 118.91 MB | Media Algo B: 126.71 MB
Estadístico T: -2.5362
Valor-p: 1.3347e-02
```

Resultados de la Tarea 2:



```
***  
--- Análisis Pareado: Impacto del Nuevo Firewall ---  
Media Diferencias (Antes - Después): 3.33 ms  
Estadístico T Pareado: 12.3359  
Valor-p (1 cola): 3.2787e-09  
Conclusión: Se RECHAZA H0. El firewall redujo significativamente la latencia.
```

Resultados Tarea 3:

```
*** Estadístico t: 0.7448  
Valor p: 0.4565
```

Resultados Tarea 4:

```
*** --- Uso de Levene ---  
Estadístico de Levene: 3.0700  
Valor-p de Levene: 0.0840  
  
Resultado: Homocedasticidad confirmada  
Por lo tanto se usa el método: Prueba T de Student clásica (varianzas iguales)  
-----  
Estadístico T final: -2.5362  
Valor-p final: 1.3347e-02
```

7. Preguntas de Control:

1. **¿Por qué es un error metodológico grave aplicar una prueba T para muestras independientes (Tarea 1) en el escenario de la Tarea 2 (evaluación antes/después del firewall en los mismos servidores)? Explique el impacto en el término de covarianza.**

Es un error usar la prueba T para muestras independientes porque las mediciones antes y después del firewall corresponden a los mismos servidores, por lo que los datos están relacionados. Al asumir que son independientes, se ignora la relación (covarianza) entre las mediciones y se pueden obtener resultados y conclusiones estadísticas incorrectas. Por ello, en este caso debe utilizarse la prueba T para muestras pareadas

2. **Describa matemáticamente y gráficamente qué es la "Prueba T de Welch". ¿Qué parámetro fundamental (calculado a partir de n y la varianza) ajusta esta prueba para evitar cometer Errores Tipo I al comparar distribuciones muy dispares?**

Los grados de libertad efectivos

Cuando las varianzas son heterocedásticas ($s_1^2 \neq s_2^2$), el estadístico t no sigue una distribución estándar. Welch corrige esto transformando los grados de libertad (ν) mediante la ecuación de Welch-Satterthwaite:

$$\nu \approx \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2} \right)^2}{\frac{\left(\frac{s_1^2}{n_1} \right)^2}{n_1 - 1} + \frac{\left(\frac{s_2^2}{n_2} \right)^2}{n_2 - 1}}$$

Al ignorar la disparidad de varianzas, la curva t teórica es demasiado alta y estrecha. El umbral crítico es bajo, lo que infla los falsos positivos (Error Tipo I)

El ajuste reduce drásticamente los grados de libertad (ν). Gráficamente, esto aplana la curva t y ensancha sus colas. Al hacer la distribución más robusta, los valores críticos se vuelven más exigentes, manteniendo el Error Tipo I bajo estricto control ($\alpha = 0.05$).

3. En el análisis de su Proyecto Integrador (Tarea 3), si el Intervalo de Confianza para la *diferencia de medias* ($\mu_1 - \mu_2$) incluyera al número cero (0), ¿cuál sería inevitablemente el resultado de su prueba de hipótesis usando $\alpha = 0.05$?
4. Según lo investigado en la Tarea 4 (ABI), si el Test de Levene arroja un valor- $p = 0.85$, ¿cuál es la conclusión estadística respecto a las varianzas y qué versión del Test T debería usar?
5. En el mundo real del Data Science, ¿cómo difiere el concepto estadístico clásico enseñado hoy frente a la ejecución comercial de un "A/B Testing" en plataformas web (ej. comparar el color de un botón de compra)?

El concepto clásico de la estadística busca certeza científica absoluta, mientras que la ejecución comercial busca velocidad para la toma de decisiones de negocio. Las diferencias clave son:

- **Peeking:** Mientras que la estadística tradicional prohíbe mirar los datos antes de tiempo para evitar falsos positivos, el negocio exige ver resultados diarios. Por esto, la industria web está reemplazando el enfoque clásico (Frecuentista) por la **Estadística Bayesiana** y algoritmos adaptativos (*Multi-Armed Bandits*), que permiten tomar decisiones sobre la marcha de forma matemáticamente válida.
- **El tamaño de la muestra:** En la teoría se esperan meses para acumular muestras gigantescas que detecten cambios mínimos. En el comercio digital, el costo de oportunidad de tener una web en espera es demasiado alto. El Data Scientist comercial ajusta el diseño del test para detectar solo efectos grandes, cerrando los experimentos rápido si no mueven la aguja del negocio.
- **Efecto Novedad y Ciclos:** Los modelos teóricos asumen datos estables y homogéneos. En la web, por ejemplo, cambiar el color de un botón genera un pico artificial de clics solo por ser algo novedoso. Para limpiar este sesgo y promediar los hábitos cambiantes de los usuarios (que se comportan distinto un martes frente a un domingo), los experimentos reales se obligan a correr en ciclos cerrados de semanas completas (7 o 14 días).

8. Conclusiones.



9. Bibliografía

- [1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.
- [2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.
- [3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	

11. Anexos

Enlace al google colab:
<https://colab.research.google.com/drive/1keYuGw9s73hG6FmYrBAVlk72xYyQofO2?usp=sharing>